

La comparaison des séquences ADN à grande échelle

Fiche de synthèse — alignement de séquences, programmation dynamique et recherche à l'échelle du génome

Problématique retenue

En quoi l'alignement de séquences ADN n'est-il qu'une application biologique d'un algorithme d'informatique déjà connu (la distance d'édition) ? Et comment passe-t-on de cet algorithme, coûteux, à des outils capables de comparer un fragment à un génome entier de plusieurs milliards de lettres ?

1. Le problème posé

Une séquence ADN est une simple suite de lettres parmi quatre : A, T, C, G. Comparer deux séquences revient à se demander si elles se ressemblent, malgré :

- des **substitutions** : une lettre remplacée par une autre
- des **insertions** : une lettre ajoutée
- des **délétions** : une lettre supprimée

C'est exactement le même problème qu'un correcteur orthographique qui doit reconnaître deux mots proches malgré des fautes de frappe (ex : « ordinateur » et « ordinatuer »). En informatique, ce problème générique s'appelle la **distance d'édition** (ou distance de Levenshtein).

Séquence 1 : ATCGTACGTA

Séquence 2 : ATCGTTCGTA

2. Pourquoi la comparaison brute est trop lente

Tester toutes les façons possibles d'aligner deux séquences (avec insertions/délétions à chaque position) coûte un temps **exponentiel** : le nombre de possibilités explose avec la longueur des séquences. Pour deux séquences de quelques centaines de lettres, une approche naïve devient déjà impraticable — alors pour un génome humain (~3 milliards de lettres), c'est totalement hors de portée.

3. La solution : la programmation dynamique

L'idée clé (utilisée par l'algorithme de **Needleman-Wunsch**, 1970) : au lieu de refaire les calculs depuis zéro, on construit une **grille** où chaque case représente le meilleur score d'alignement possible jusqu'à ce point. Chaque case se déduit des cases voisines déjà calculées — on ne recalcule jamais deux fois la même chose.

Les trois règles de score

- **Match** (lettres identiques) → bonus (ex : +1)
- **Mismatch** (lettres différentes) → pénalité (ex : -1)
- **Gap** (insertion/délétion, un « trou ») → pénalité (ex : -2)

Complexité obtenue

Grâce à cette grille, la complexité passe d'exponentielle à **$O(n \times m)$** (n et m étant les longueurs des deux séquences) : un temps de calcul raisonnable, proportionnel au produit des deux tailles.

À retenir pour l'oral

Needleman-Wunsch n'est rien d'autre qu'une distance d'édition appliquée à l'ADN. C'est un algorithme d'informatique générale, pas un algorithme inventé pour la biologie.

4. Passer à l'échelle : le vrai défi du « grand échelle »

$O(n \times m)$ reste beaucoup trop lent quand une des deux séquences est un génome entier de plusieurs milliards de lettres. Comparer un fragment ADN à tout le génome, case par case, prendrait des heures, voire des jours. Il faut donc une approche différente : ne plus tout comparer, mais **chercher intelligemment**.

L'idée : indexer avant de chercher

C'est le même principe qu'un moteur de recherche web : Google n'analyse pas chaque page à chaque requête, il a déjà construit un **index** à l'avance. Pour l'ADN :

- On découpe les séquences en petits fragments de taille fixe, les **k-mers** (ex : tous les fragments de 5 lettres : ATCGT, TCGTA...)
- On stocke ces k-mers dans une **table de hachage** : « ce k-mer apparaît à telle position »
- Pour chercher un fragment, on découpe la requête en k-mers, on retrouve instantanément les zones candidates via la table de hachage
- On ne vérifie en détail (avec l'alignement complet) que ces quelques zones candidates, au lieu de tout le génome

BLAST

C'est exactement le principe derrière **BLAST** (Basic Local Alignment Search Tool), l'outil que tous les biologistes utilisent au quotidien pour interroger des bases de données génomiques entières en quelques secondes.

5. Comparaison des approches

Approche	Principe	Complexité / usage
Comparaison brute (force brute)	Tester toutes les combinaisons d'alignements possibles	Exponentiel — inutilisable en pratique
Needleman-Wunsch (programmation dynamique)	Grille de scores construite progressivement	$O(n \times m)$ — adapté à 2 séquences courtes
BLAST (k-mers + hachage)	Indexation puis recherche ciblée par zones candidates	Quasi instantané — adapté à un génome entier

6. Dans quoi c'est utilisé

Recherche médicale et diagnostic

- Identifier des mutations responsables de maladies génétiques (cancers, maladies rares)
- Comparer l'ADN d'un patient à des bases de référence pour repérer des anomalies

Virologie et épidémiologie

- Identifier rapidement un nouveau virus en le comparant aux virus déjà connus (ex : identification rapide du SARS-CoV-2 comme coronavirus, proche du SARS de 2003)
- Suivre l'évolution des variants (comparaison de milliers de génomes viraux entre eux)

Médecine légale et identification

- Comparaison de profils ADN (empreintes génétiques)

Recherche évolutive

- Construire des arbres phylogénétiques (proximité génétique entre espèces)
- Comprendre comment les espèces ont divergé au fil du temps

Agronomie et environnement

- Identifier des espèces à partir d'un échantillon ADN environnemental (barcoding), utile pour cataloguer la biodiversité

Recherche pharmaceutique

- Comparer des séquences de protéines pour trouver des cibles thérapeutiques ou des gènes similaires entre organismes

7. En quoi c'est une innovation

1. Le changement d'échelle, pas l'algorithme lui-même

L'innovation n'est pas d'avoir inventé un nouvel algorithme « magique » — Needleman-Wunsch existe depuis 1970. L'innovation, c'est d'avoir réutilisé un vieux principe informatique (la distance d'édition) et de l'avoir fait passer à l'échelle du vivant, où les données sont énormes (milliards de lettres) et augmentent sans cesse.

2. Un changement de paradigme : indexer plutôt que comparer

Passer de « je compare tout à tout » (Needleman-Wunsch) à « je cherche intelligemment » (BLAST, k-mers) est un vrai saut conceptuel — le même que celui qui a permis aux moteurs de recherche web d'exister. C'est une innovation algorithmique, pas biologique.

3. Un effet d'accélération massif sur la science

Avant ces outils, comparer des génomes prenait des années de travail manuel. Aujourd'hui, une recherche dans une base de données mondiale prend quelques secondes. Cela a rendu possible des disciplines entières (génomique comparative, épidémiologie génomique en temps réel).

4. Un pont entre deux mondes

C'est une innovation « de transfert » : elle a fait entrer l'algorithmique du texte (théorie des langages, structures de données) dans la biologie, créant un nouveau champ — la bio-informatique — là où les deux disciplines n'avaient a priori rien en commun.

8. Plan de présentation suggéré

- 1. Le problème générique : comparer deux textes malgré des erreurs (distance d'édition)
- 2. Pourquoi la force brute est trop lente (complexité exponentielle)
- 3. La solution : programmation dynamique et Needleman-Wunsch (démonstration sur un petit exemple)
- 4. Le vrai défi à grande échelle : passer de 2 séquences courtes à un génome entier
- 5. L'indexation : k-mers, table de hachage, et le fonctionnement de BLAST
- 6. Un exemple concret parlant (identification virale, diagnostic)
- 7. Conclusion : la bio-informatique réutilise l'algorithmique classique